2023 年链家二手房数据分析报告

胡洽

2024-10-31

你的主要发现

1. 价格偏高的二手房所在区域与挂牌数量多的区域没有重合
2. 普遍认为的房屋朝向对房屋单价的影响，在样本数据中表现的不明显
3. 黄埔永清、CBD 西北路、中北路，这三个属于比较热门的片区，单价高而且关注人数不低

数据介绍

本报告链家数据获取方式如下：

报告人在 2023 年 9 月 12 日获取了链家武汉二手房网站数据。

- 链家二手房网站默认显示 100 页，每页 30 套房产，因此本数据包括 3000 套房产信息；
- 数据包括了页面可见部分的文本信息，具体字段及说明见作业说明。

说明：数据仅用于教学；由于不清楚链家数据的展示规则，因此数据可能并不是武汉二手房市场的随机抽样，结论很可能有很大的偏差，甚至可能是错误的。

数据概览

数据表（lj）共包括 property_name, property_region, price_ttl, price_sqm, bedrooms, livingrooms, building_area, directions1, directions2, decoration, property_t_height, property_height, property_style, followers, near_subway, if_2y, has_key, vr 等 18 个变量，共 3000 行。表的前 10 行示例如下：

Table 1: 武汉链家二手房

property_name	property_region	price_ttl	price_sqm	bedrooms	livingrooms	building_area	directions1	directions2	decoration	property_t_height	property_height	property_style	followers	near_subway	if_2y	has_key	vr
南湖名都 A 区	南湖沃尔玛光谷东	237.0	18709	3	1	126.68	南	北	精装	17	中	塔楼	3	近地铁	NA	随时看房	NA
万科紫悦湾	光谷东	127.0	14613	3	2	86.91	南	NA	精装	28	中	板楼	1	NA	房本满两年	随时看房	VR 看装修

property_name	property_region	price	unit_price	bedroom	livingroom	building_area	direction1	direction2	decoration	property_t_height	property_height	property_style	followers	near_subway	if_2y	has_key	vr
东立国际	二七	75.0	15968	1	1	46.97	南	NA	简装	18	低	塔楼	3	近地铁	NA	随时看房	NA
新都汇	光谷广场	188.0	15702	3	2	119.73	北	东	精装	32	高	塔楼	2	近地铁	房本满两年	随时看房	NA
保利城一期	团结大道	182.0	17509	3	2	103.95	东南	NA	简装	34	中	板塔结合	3	NA	房本满两年	随时看房	VR看装修
加州橘郡	庙山	122.0	10376	3	2	117.59	南	北	精装	34	低	板楼	1	NA	房本满两年	随时看房	NA
省建筑五公司西区	光谷广场	99.0	12346	2	1	80.19	南	NA	简装	7	低	板楼	0	近地铁	NA	随时看房	VR看装修
保利上城东区	白沙洲	193.8	16336	3	2	118.64	南	北	其他	34	中	板塔结合	0	近地铁	房本满两年	随时看房	NA
石化大院	中南丁字桥	325.0	32631	4	1	99.60	南	北	简装	5	低	板楼	2	近地铁	NA	随时看房	NA
阳光花园	杨汉湖	192.0	17403	3	2	110.33	南	北	其他	7	低	板楼	0	近地铁	房本满两年	随时看房	NA

各变量的简短信息:

各变量的简短统计:

可以看到:

- 房屋总价跨度从 10.6w 到 1380w, 整体跨度区间极大。第一分位数 (95w) 和第三分位数 (188w)，估计大部分房屋总价集中在 100-200w 之间, 房屋单价分布在 10000-20000 居多。
- 从房屋挂牌数上看，市场上比较多的房屋类型是: 精装、南北朝向、中楼层、板楼
- 从房屋房间数看，大部分是 2 室或 3 室

探索性分析

price_ttl 的数值描述与图形

Table 2: price_ttl 数值分析

Statistic	Value
Mean	155.86278
Median	137
Mode	105
Variance	9129.44477979821
Standard Deviation	95.5481280810786
Range	10.6 to 1380
IQR	93
Skewness	2.75322271453055
Kurtosis	16.11671561457

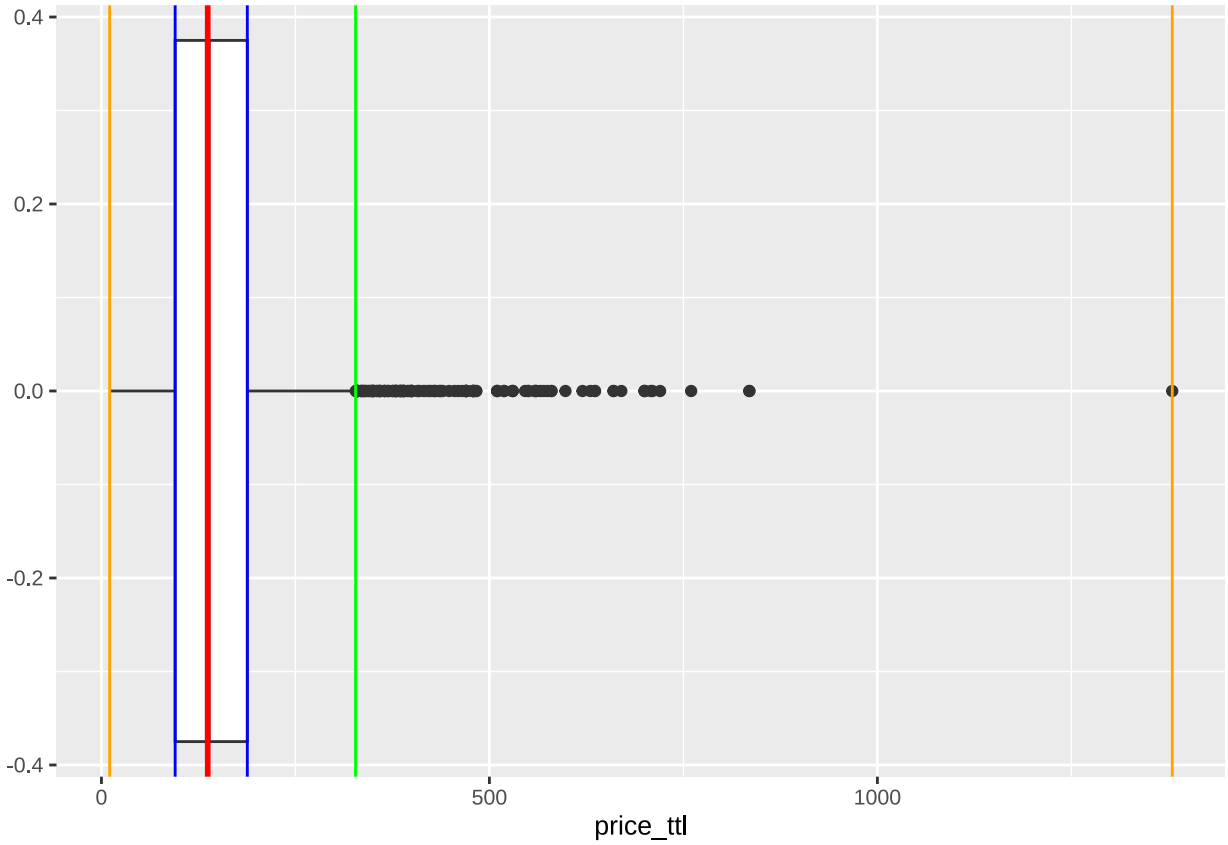

Table 3: 挂牌数前 5 名的区域

property_region	count
白沙洲	167
盘龙城	126
四新	116
光谷东	112

property_region	count
金银湖	97

Table 4: 高离散值前 5 名的区域

property_region	count
积玉桥	21
中北路	11
CBD 西北湖	9
中南丁字桥	9
黄埔永清	8

发现:

- 二手房均价为 155.9w, IQR 为 93w，数据相对还是比较集中，50% 的数据在 95w-188w 之间。
- 偏度 >0, 长尾在右侧，较多总价集中在左侧，这与线框图的图形特征相符。从箱线图看，右须较长，存在较多的离散值
- 挂牌数量前 5 位的区域是白沙洲、盘龙城、四新、光谷东、金银湖; 而价格偏高的房屋所在区域, 排在前五的是: 积玉桥、中北路、CBD 西北湖、中南丁字桥、黄埔永清。价格高的房屋都不在挂牌数量多的区域。

property_name 的数值描述与图形

Table 5: 小区挂牌数 top10

property_name	count
东立国际	22
保利中央公馆	16
朗诗里程	16
恒大名都	15
阳光 100 大湖第	15
保利城一期	13
锦绣龙城	13
保利华都	12
统建同安家园	12
金地自在城 K2	12

Table 6: 小区关注度 top10

property_name	count
中环星干线	336
万达公馆	278
十里和府	262
米兰映象	241
联投花山郡一期（香颂）	236
江汉人家	215
保利心语六期	212
阜华领秀中南	209

property_name	count
中建东湖锦城	208
保利中央公馆	197

发现:

- 挂牌小区词条出现最多的是” 国际”
- 小区挂牌数前 3 位是: 东立国际、保利中央公馆、朗诗里程
- 小区关注度最高的前 3 位是: 中环星干线、万达公馆、十里河府

变量 followers 的数值描述与图形

Table 7: followers 数值分析

Statistic	Value
Mean	6.6136666666667
Median	3
Mode	0
Variance	231.557599088586
Standard Deviation	15.2170167604753
Range	0 to 262
IQR	5
Skewness	6.90076729401956
Kurtosis	68.1705707707924

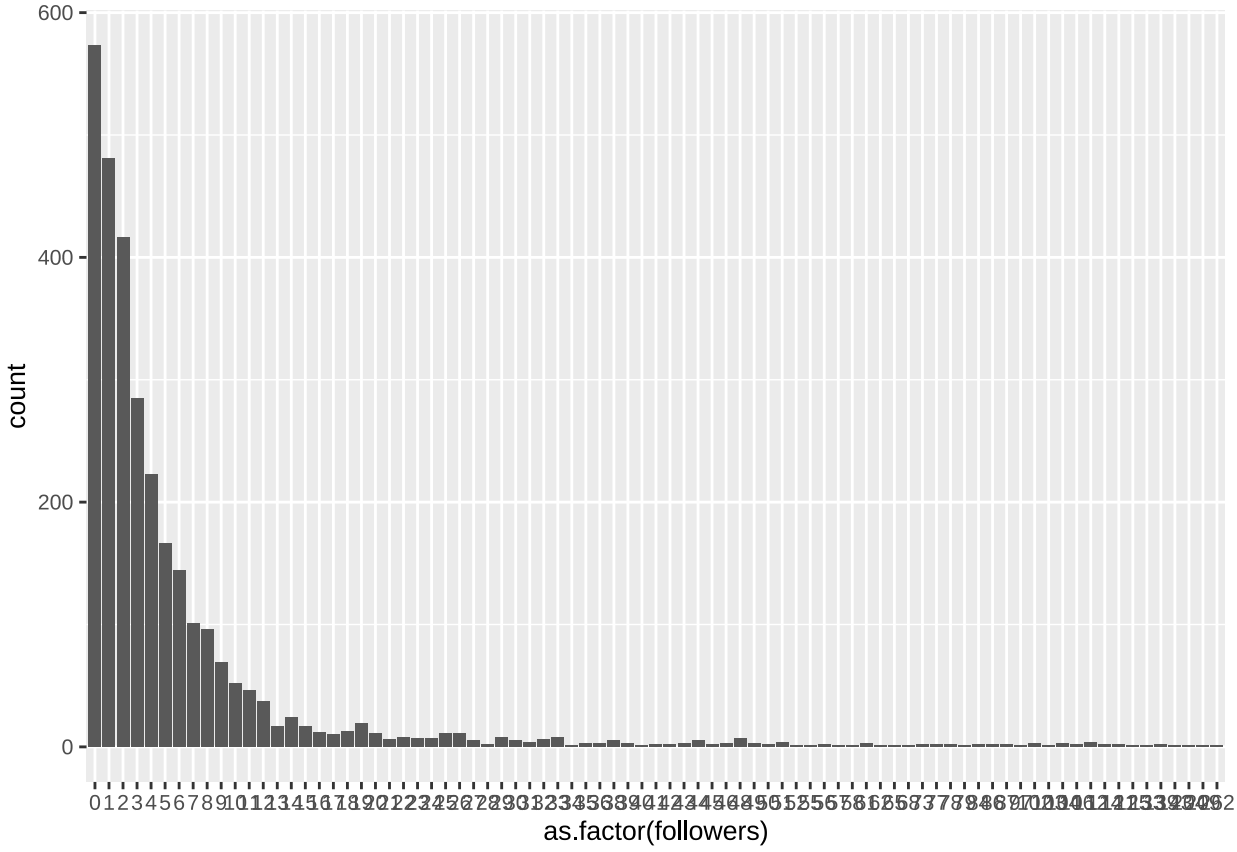


```
## <ggproto object: Class ScaleDiscretePosition, ScaleDiscrete, Scale, gg>
##     aesthetics: x xmin xmax xend
##     axis_order: function
##     break_info: function
##     break_positions: function
##     breaks: waiver
##     call: call
##     clone: function
##     dimension: function
##     drop: TRUE
##     expand: waiver
##     get_breaks: function
##     get_breaks_minor: function
##     get_labels: function
##     get_limits: function
##     get_transformation: function
##     guide: waiver
##     is_discrete: function
##     is_empty: function
##     labels: waiver
##     limits: 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 ...
##     make_sec_title: function
##     make_title: function
##     map: function
##     map_df: function
##     n.breaks.cache: NULL
```

```
##     na.translate: TRUE
##     na.value: NA
##     name: waiver
##     palette: function
##     palette.cache: NULL
##     position: bottom
##     range: environment
##     range_c: environment
##     rescale: function
##     reset: function
##     train: function
##     train_df: function
##     transform: function
##     transform_df: function
##     super:  <ggproto object: Class ScaleDiscretePosition, ScaleDiscrete, Scale, gg>
```

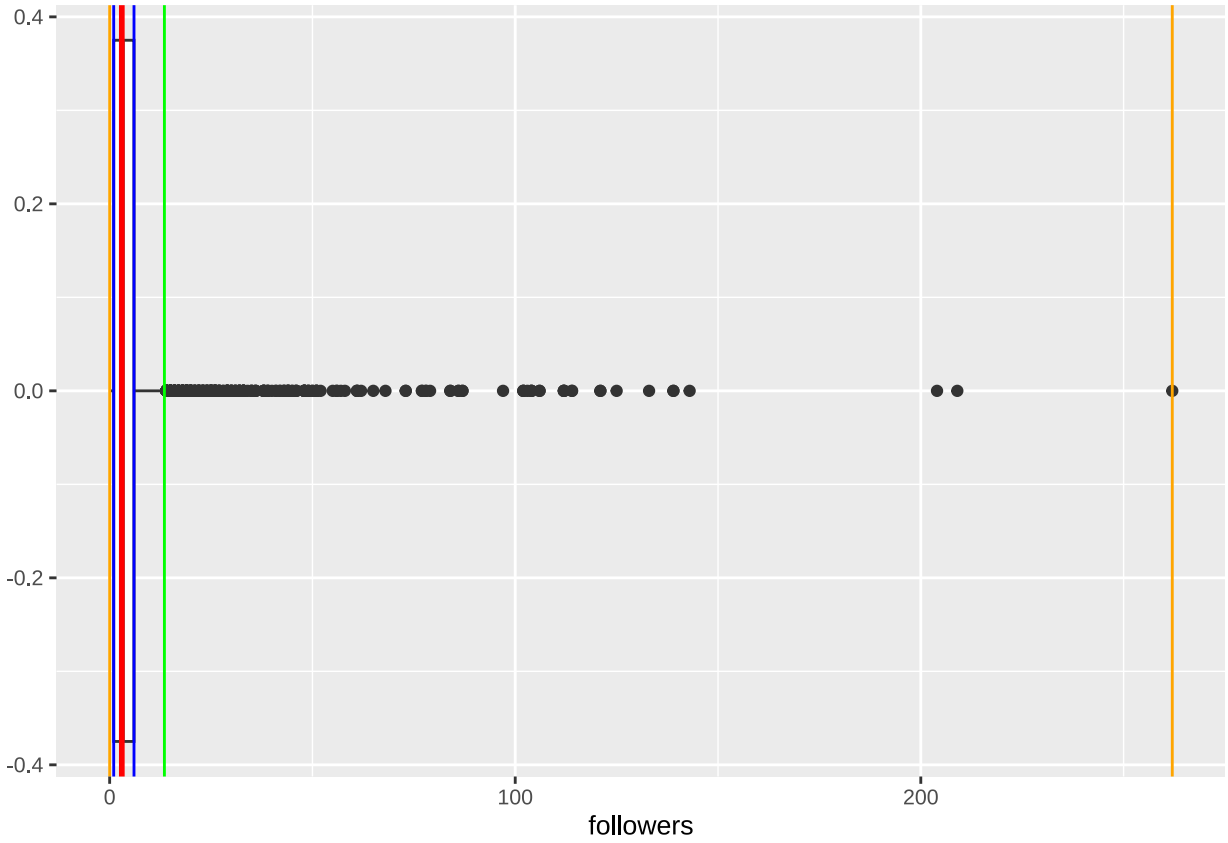


```
## [1] 4.004219
```

发现：

- 房屋关注人数范围从 0-262, 差别极大
- 偏度 >0, 长尾在右侧，较多总价集中在左侧，这与线框图的图形特征相符。从箱线图看，右须较长，存在较多的离散值
- 整体的关注人数平均值为 6.6，除去离散点后的平均值为 4，两者相差较大，说明在数据分析过程中不仅要看整体，也需要分析是否存在个别离散数据对整体造成较大影响

探索问题 1：房屋朝向对单价是否存在影响

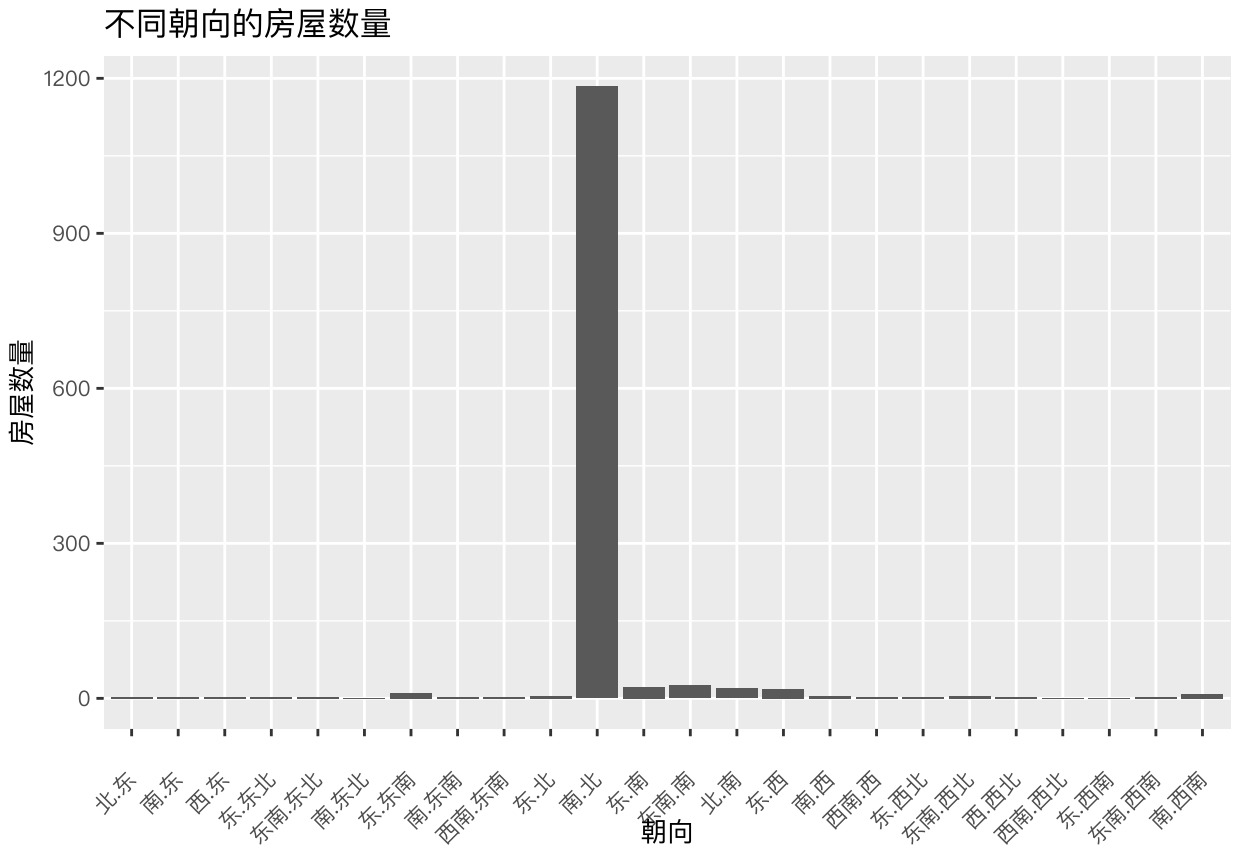

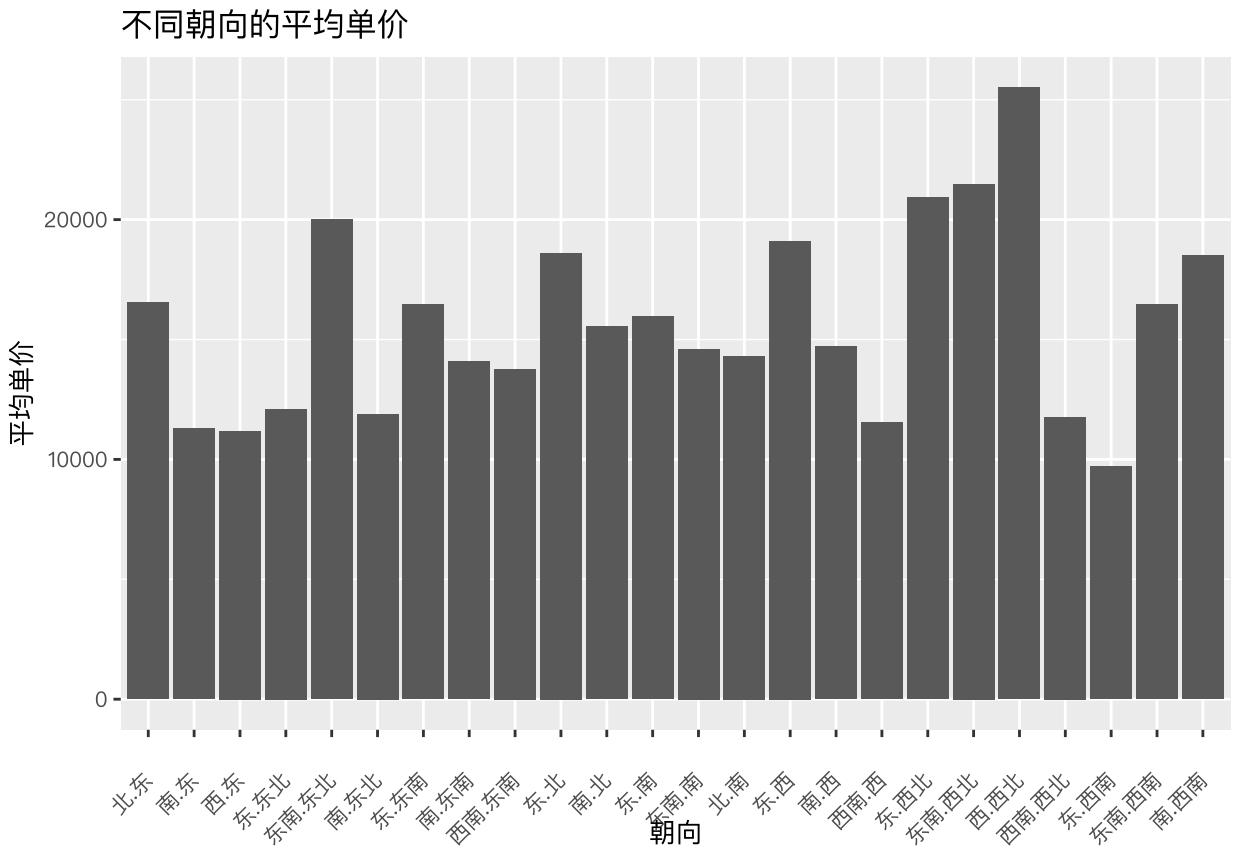

发现:

- 南北朝向的二手房挂牌数最多
- 朝向对房屋的单价影响不大

探索问题 2：单价高和关注高的主要在哪些片区

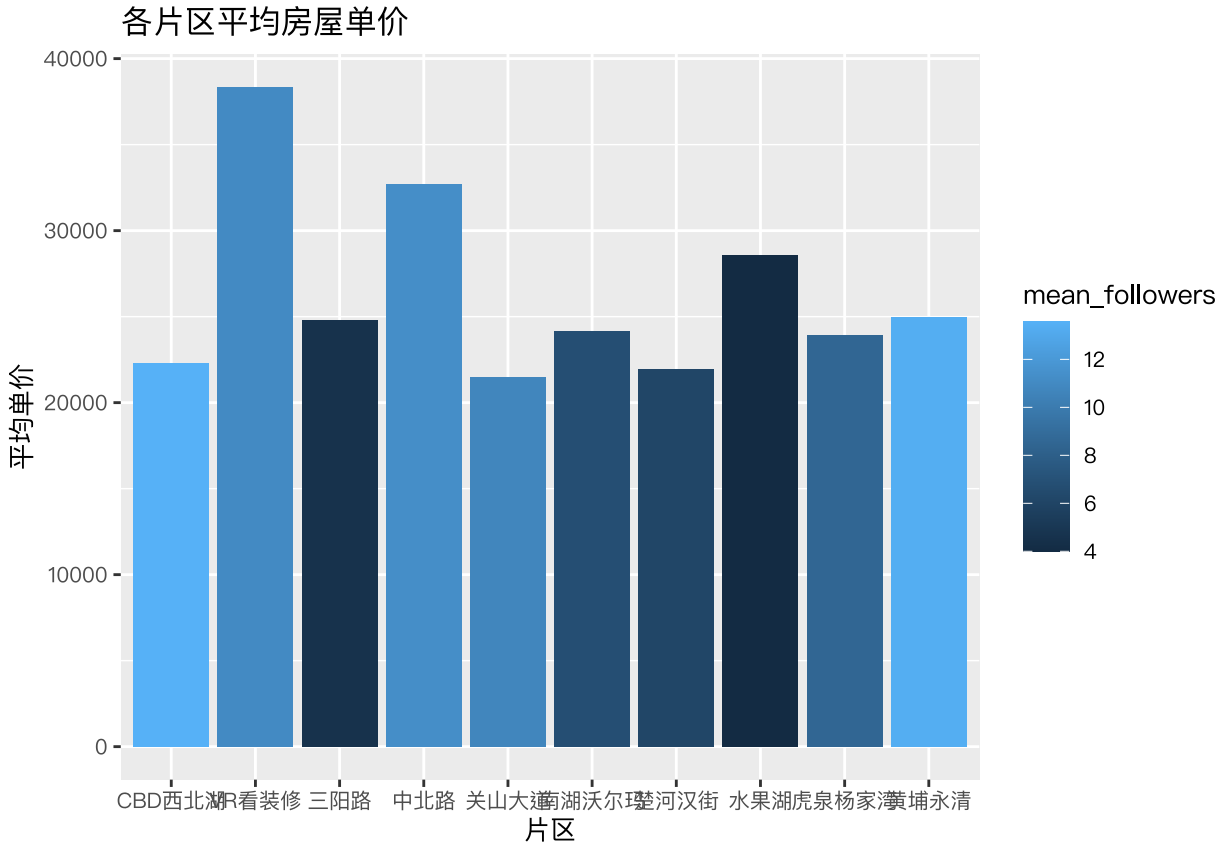

发现：

- 单价高而且关注高的片区是：黄埔永清、CBD 西北路、VR 看装修 (可能是脏数据)、中北路

探索问题 3：建筑类型对房价的影响

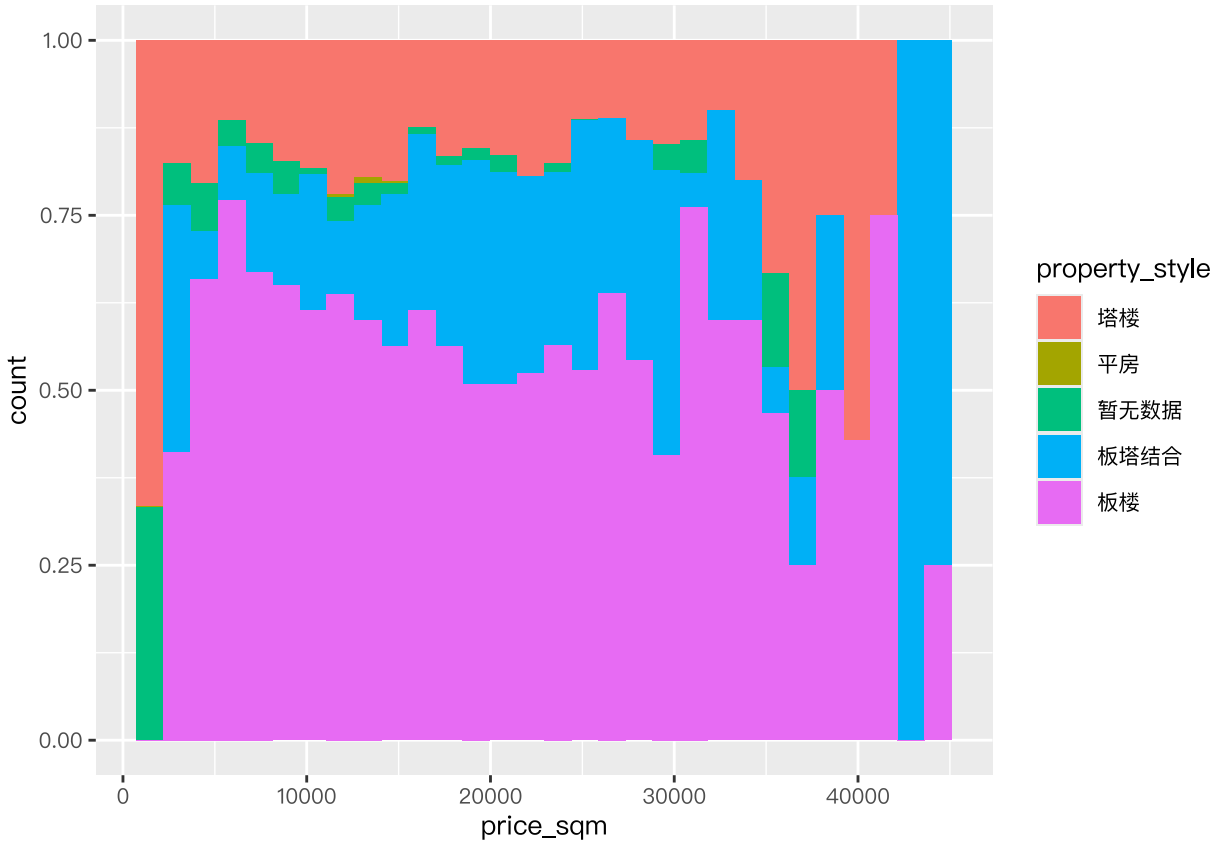

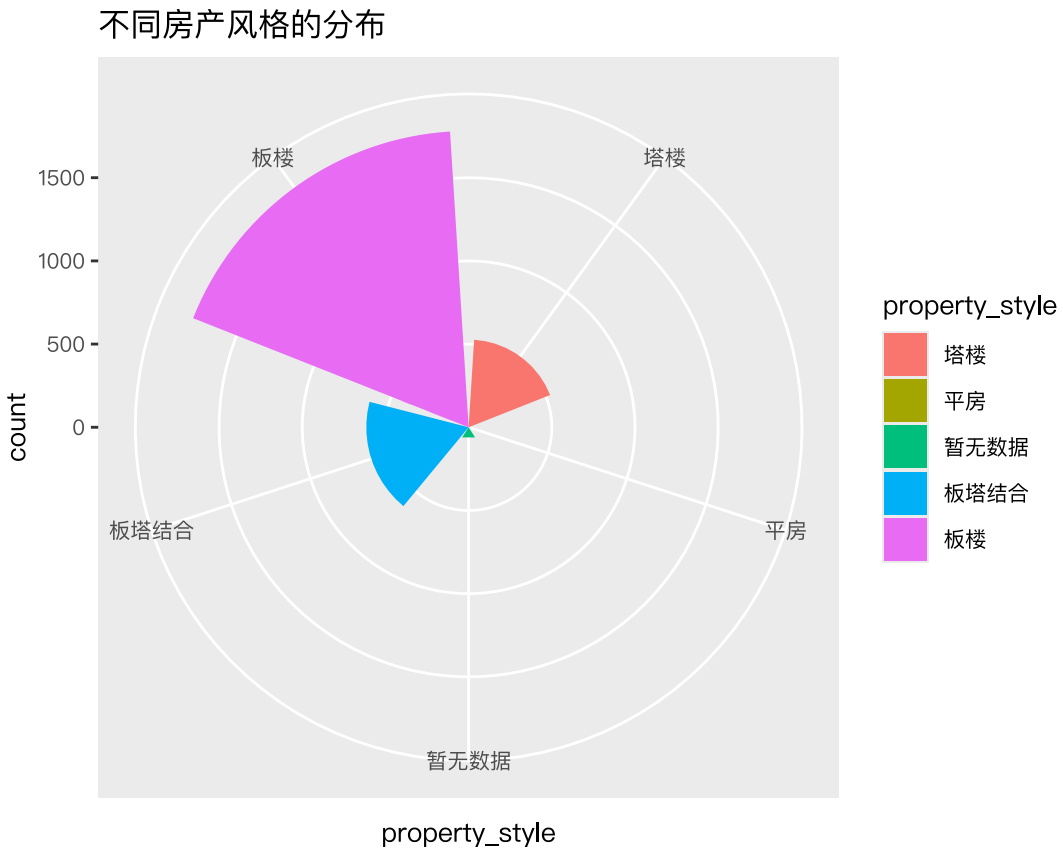

发现：

- 建筑形式最多的是板楼，其次是板塔结合，再次是塔楼。
- 房屋单价上看不出与建筑类型有比较强的关联关系

发现总结

从上面的数据分析中，数据分析是一个比较抽象的过程，特别是在探索性发现的过程中，你常识中预测的时间结果可能与最终分析的结果不一致。